Java 8 - Streams

Inhaltsverzeichnis

Abstract

Zunächst werden die Grundideen und der Nutzen von Streams im Allgemeinen beleuchtet. Dabei werden Grundlagen und nützliche Eigenschaften mit Beispielen verdeutlicht. Im Hauptteil werden wichtige Methoden aus dem Interface `Stream<T>` in die Kategorien intermediate, terminal und short-circuit Methoden eingeteilt und mit, vor Java 8 nutzbaren, Funktionen in diversen Benchmarks vergleichen. Dabei stellt sich heraus, dass sequentielle Streams in den meisten Fällen keinen Performancegewinn bringen, dafür aber ein wichtiger Schritt in Richtung automatischer Parallelisierung sind.

Streams

Konzept

Streams sind Hüllen um Datenquellen wie Arrays oder Listen[1]. Diese erweitern die Datenquellen um Eigenschaften an denen es ihnen ansonsten fehlt. Folgend sind drei der nützlichsten neuen Eigenschaften aufgeführt[2]:

Lazy evaluation
Die Ausführung von Methoden wird so lange herausgezögert, bis eine Evaluation zwingend notwendig ist[3].
Dieses Konzept findet zum Beispiel in funktionalen Programmiersprachen wie Haskell Verwendung.

Automatische Parallelisierung
Wenn ein Stream als parallel gekennzeichnet ist, werden Operationen auf ihm automatisch nebenläufig ausgeführt.

Unendliche Streams
Streams können aus einer Generatorfunktion erzeugt werden. Diese Funktion erzeugt während der Verarbeitung des Streams beliebig viele neue Einträge[4].

Umsetzung

Streams können aus vielen verschiedenen Datenquellen erzeugt werden. Beispiele sind beliebige Collections, native Arrays, Generatorfunktionen oder I/O-Kanäle[5]. Ein solches erzeugtes Stream-Objekt hält selber keine Daten, sondern ist nur eine Hülle um die jeweilige bestehende Datenquelle. Dabei können Streams die Datenquelle nicht verändern (nur

[1] vgl. [MHS1] Folie 7
[2] vgl. [MHS1] Folie 6
[3] vgl. [MHS1] Folie 43
[4] vgl. [MHS1] Folie 9
[5] vgl. [J8API] java.util.stream.Stream<T>

Elemente filtern) und gewähren keinen indexierten Zugriff auf diese. Dadurch soll erreicht werden, dass Streams möglichst leichtgewichtig und performant sind[6].
Diese Eigenschaften stehen sie im Kontrast zu Collections, die sich ihre eigenen Daten halten und verwalten[7].

Auf einem Stream lässt sich eine beliebige Anzahl aneinander gereihter intermediate Methoden anwenden, die selber jeweils wieder einen Stream erzeugen. Diese intermediate Methoden nutzen in der Regel die, in Java 8 hinzugekommenden, Lambda-Ausdrücke. Gängige Beispiele hierfür sind map oder filter.
Ein Stream wird mit einer einzelnen terminal Methode abgeschlossen. Diese terminal Methode darf im Gegensatz zu den intermediate Methoden Seiteneffekte haben und einen Wert zurückgeben[8]. Durch die Benutzung von Streams mit Quelle, intermediate Methode und abschließender terminal Methode wird eine Stream-Pipeline erstellt, durch die die Elemente des Streams gereicht werden.[9]

Beispiel 1 - Erzeugung und Benutzung eines Streams[10]

```
1. List<Integer> foo = new ArrayList<Integer>(Arrays.asList(1, 2,
   3, 4, 5, 6, 7, 8, 9, 10));
2. foo.stream().
        filter(i -> i % 2 == 0).
        forEach(System.out::println);
```

In diesem Beispiel wird in Zeile 1 zunächst eine Liste aus Integern mit dem Namen `foo` erzeugt. In Zeile 2 wird dann die Methode `stream` aus `java.util.Collection` benutzt um einen Stream aus Integern zu initialisieren.
Auf diesen Stream wird nun die Methode `filter` mit einem Lambda-Ausdruck aufgerufen, der für gerade Zahlen `true` und für ungerade Zahlen `false` ausgibt. Die Methode `filter` ist eine Intermediate-Methode, weil sie einen neuen Stream aus allen, nicht herausgefilterten, Elementen erzeugt.
Auf den gefilterten Stream wird dann die Methode `forEach` mit einem einfachen `System.out::println` aufgerufen, um die übrig gebliebenen Elemente anzuzeigen. Die Methode `forEach` ist eine Terminal-Methode, allerdings macht sie in diesem Fall keinen Gebrauch von Seiteneffekten.

---

[6] vgl. [MHS1] Folie 6-8
[7] vgl. [MHS1] Folie 11
[8] vgl. [MHS1] Folie 44
[9] vgl. [J8API] java.util.stream.Stream<T>
[10] vgl. [CANH] vgl. beispiele.Generierung

Streams können aus Generatormethoden erzeugt werden. Hierzu lässt sich die statische default Methode `generate` aus dem Stream-Interface nutzen. Diese Generator Methode erzeugt einen unendlichen, sequentiellen, ungeordneten Stream der sich gut dazu eignet, eine große Menge beliebig erzeugbarer Elemente zu verarbeiten[11].

Beispiel 2 - Erzeugung eines Streams mit einer Generator-Methode[12]

```
1. private static Integer generator() {
2.     return i++;
3. }
4. Stream.generate(Generierung::generator)
```

In diesem Beispiel wird ein Stream mittels einer Generator-Methode erzeugt. Die Generator-Methode (Zeile 1-3) basiert auf einer Zählvariablen, die in jedem Schritt inkrementiert wird. In Zeile 4 wird die Methode `generate` aus `Stream` aufgerufen. Immer wenn der Stream nun ein Element benötigt ruft er die Generator-Methode auf.

Um Streams performanter zu machen werden viele Methoden (z.B. map oder filter) erst aufgerufen wenn von ihnen ein Element gefordert wird - sie setzen also lazy-evaluation um. Dazu kommen short-circuit Methoden, die oftmals nur wenige Elemente aus den vorherigen Streams benötigen um zu terminieren. Wenn nun eine short-circuit Methode nach einer Methode mit lazy-evaluation aufgerufen wird, so wird die Methode mit lazy-evaluation nur so viele Elemente zunächst verarbeiten und dann neu erzeugen, wie die short-circuit Methode benötigt.

Beispiel 3 - Funktionalität von Short-Circuit-Methoden[13]

```
Stream.of(1, 2, 3, 4, 5, 6, 7, 8, 9, 10).
     map(i -> {
          System.out.println("Map has been called!");
          return i;
     }).
     limit(3).
     forEach(System.out::println);
```

[11] vgl. [J8API] java.util.stream.Stream<T>
[12] vgl. [CANH] beispiele.Generierung
[13] [CANH] beispiele.ShortCircuitMethoden

Programm Output:

```
Map has been called!
1
Map has been called!
2
Map has been called!
3
```

In diesem Beispiel wird ein Stream aus den Zahlen 1 bis 10 erzeugt und die Methode `map` aufgerufen. Auf dem erzeugten Stream wird die Methode `limit` mit einer Beschränkung von 3 aufgerufen. Zuletzt werden die übrig gebliebenen per `System.out::println` ausgegeben.
Es entsteht der Eindruck, als würde `map` für alle 10 Elemente aufgerufen, von denen durch `limit` aber nur 3 benutzt werden. Wie allerdings am Output zu erkennen ist, wird `map` nur genau 3 mal aufgerufen.

Um Streams noch performanter zu machen, können diese auf sehr einfache Weise parallelisiert werden. Hierzu reicht es die intermediate-Methode `parallel` aufzurufen. Wenn diese Methode aufgerufen wurde laufen alle folgenden intermediate-Methoden und die abschließende terminal-Methode nebenläufig. Hierdurch sinkt die Laufzeit der Streams fast linear mit der Anzahl der verfügbaren Prozessoren[14].

Beispiel 4 - Funktionalität von parallelen Streams[15]

```
1. Stream<Integer> serialStream = Stream.of(1, 2, 3);
2. Stream<Integer> parallelStream = Stream.of(1, 2, 3).parallel();

3. long serialStartTime = System.currentTimeMillis();
4. serialStream.forEach(ParallelStream::slowOperation);
5. long serialEndTime = System.currentTimeMillis();

6. long parallelStartTime = System.currentTimeMillis();
7. parallelStream.forEach(ParallelStream::slowOperation);
8. long parallelEndTime = System.currentTimeMillis();
```

[14] vgl. [MHS2] Folie 28
[15] [CANH] beispiele.ParallelStream

```
9. System.out.println("Serial time: " + (serialEndTime -
   serialStartTime) + " milliseconds");
10.  System.out.println("Parallel time: " + (parallelEndTime -
   parallelStartTime) + " milliseconds");
```

Output (getestet auf einem 4-Kern-Computer):
```
Serial time: 3033 milliseconds
Parallel time: 1058 milliseconds
```

In Zeile 1 wird ein Serieller Stream mit den Zahlen 1-3 initialisiert. In Zeile 2 wird sein paralleles Gegenstück erzeugt. Der einzige Schritt, der notwendig ist um diesen Stream zu parallelisieren, ist es, die Methode `parallel` aufzurufen. In den Zeilen 4 und 7 wird sowohl auf den parallelen als auch auf den seriellen Stream die Methode `slowOperation` aufgerufen. Die einzige Aufgabe dieser Methode ist es, 1 Sekunde zu warten. In den Zeilen 3, 5, 6 und 8 werden Zeitstempel genommen, um die Laufzeit der jeweiligen Stream-Aufrufe zu messen.
Wie am Output zu sehen ist, braucht der parallele Stream nur ein drittel der Laufzeit des seriellen Streams, die Elemente werden also parallel verarbeitet.

Methoden

Das Stream-Interface besitzt eine Vielzahl an Methoden, um mit diversen Streams zu arbeiten [16]. Diese Methoden lassen sich in zwei Kategorien einteilen: intermediate Methoden und terminal Methoden. Des Weiteren gibt es short-circuit Methoden welche sowohl intermediate als auch terminal Methoden sein können.
Zusammen lässt sich aus diesen Methoden eine Stream-Pipeline bauen, die mit einer Quelle beginnt, beliebig viele intermediate Methoden einthält und mit einer terminal Methode endet.

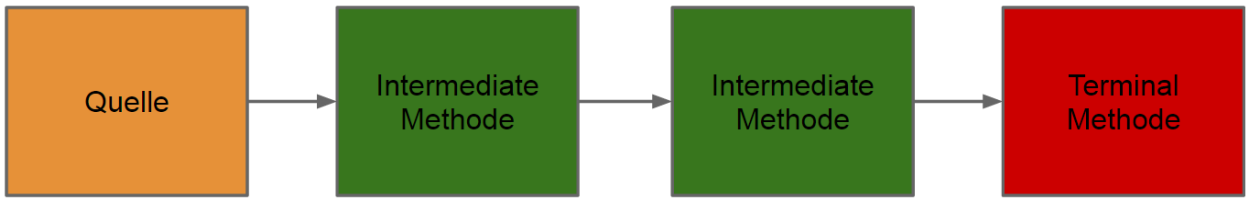

Intermediate Methoden

Diese Methoden konsumieren die Elemente des aufrufenden Streams. Zusätzlich verarbeiten, verändern oder filtern sie diese und erzeugen aus den neuen Elementen einen neuen Stream. Diese Methoden können beliebig viel hintereinander gereiht werden.
Intermediate-Methoden können in zwei weitere Kategorien eingeteilt werden: stateless und stateful Methoden. Stateless Methoden wie `filter` und `map` setzen das Prinzip der

[16] Hier werden nur einige Methoden vorgestellt. Für alle Methoden siehe [J8API] java.util.stream.Stream<T>

lazy-evaluation um. Dieses Prinzip wird soweit umgesetzt, dass kein einziges Element aus der Quelle von der erzeugten “Stream-Pipeline” verarbeitet wird, bis die terminal Methode am Ende der Pipeline aufgerufen wird. Stateful Methoden wie `distinct` und `sorted` setzen das Prinzip der lazy-evaluation nur teilweise oder gar nicht um. Dies kann bei, beispielsweise `sorted`, so weit gehen, dass vom vorherigen Stream jedes Element verarbeitet sein muss, damit `sorted` anfangen kann Elemente an die nächste Methode weiter zu geben. Des Weiteren speichern stateful Methoden im Gegensatz zu stateless Methoden Informationen von vorher verarbeiteten Elementen zwischen, um bei folgenden Elementen darauf zurückgreifen zu können[17].

Im Folgenden werden einige wichtige Intermediate-Methoden vorgestellt und Benchmarks[18] für diese gezeigt. Anschließend werden diese mit Java7-Alternativen verglichen.

map

Die Methode map ist eine der grundlegenden Methoden für die Verarbeitung von Datensammlungen. Mit ihr wird auf alle Elemente einer Datensammlung eine Funktion ausgeführt. Der Rückgabewert dieser Methode ist die veränderte Datensammlung.
Bekannt ist diese Methode beispielsweise aus funktionalen Programmiersprachen wie Haskell [19] oder dem map-reduce-Prinzip[20].

Im Stream Interface `Stream<T>` ist die Methode mit folgender Signatur definiert:

```
<R> Stream<R> map(Function<? super T,? extends R> mapper)
```

Als Argument wird also eine Funktion übergeben, die die Elemente vom selben Typ `<? super T>` aus denen der Stream besteht, konsumiert. Produzieren tut diese Methode Elemente vom Typ `<? extends R>`. Die Methode `map` produziert einen `Stream<R>`, auf dem wiederum eine beliebige intermediate oder terminal Methode aufgerufen werden kann.
Die Methode `map` gehört zu den stateless Methoden.

map-Benchmark[21]

```
1. list.stream().
2.     map(s -> s.toUpperCase()).
3.     forEach(s -> s.length());
```

[17] vgl. [J8API] java.util.stream
[18] Alle Benchmarks wurden mit dem Programm Benchmark Tool durchgeführt. (s. Anhang)
[19] [HAPI] map
[20] [DGMR]
[21] [CANH] benchmarks.intermediateMethoden.BenchmarkMap

```
4. for(String s : list) {
5.     s.toUpperCase().length();
6. }
```

In Zeile 1-3 ist der Aufruf der `map`-Benchmark Methode zu erkennen. In den Zeilen 4-6 sind die Vergleichsmethode mit einer `for`-Schleife umgesetzt. Damit die Funktion von `map` für jedes Element aufgerufen wird ist es notwendig, eine terminal Methode auf den von `map` erzeugten Stream aufzurufen. Hierfür wurde `forEach` gewählt. Die durchgeführten Operationen beim `map`-Benchmark und `for`-Benchmark sind jedoch die selben.

Ergebnisse[22]:

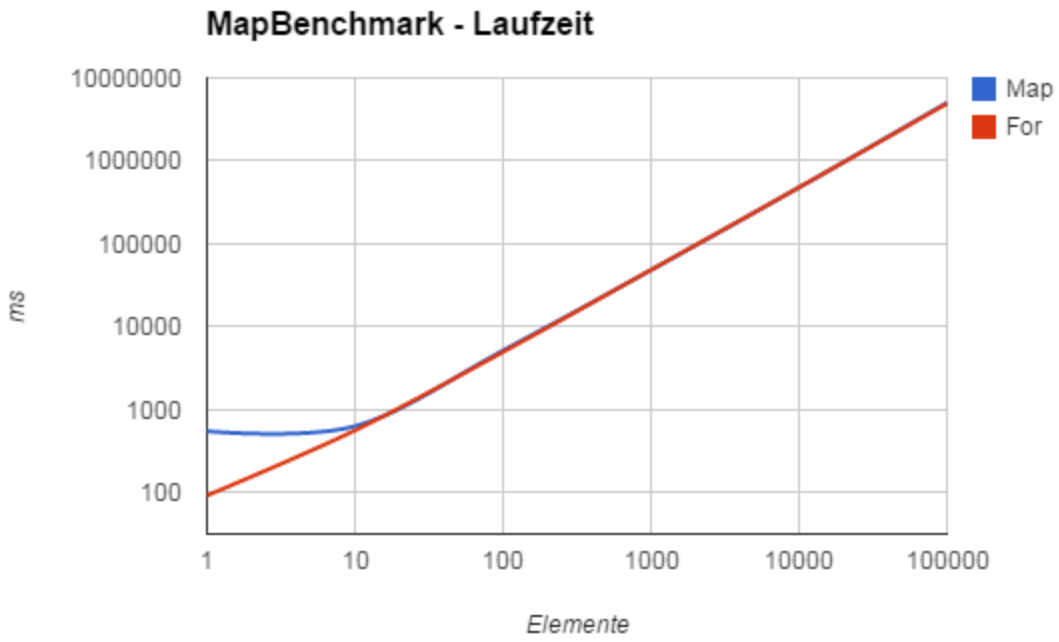

[22] [DANH] Originaloutput als csv-Datei namens “mapBenchmarkOutput.csv”

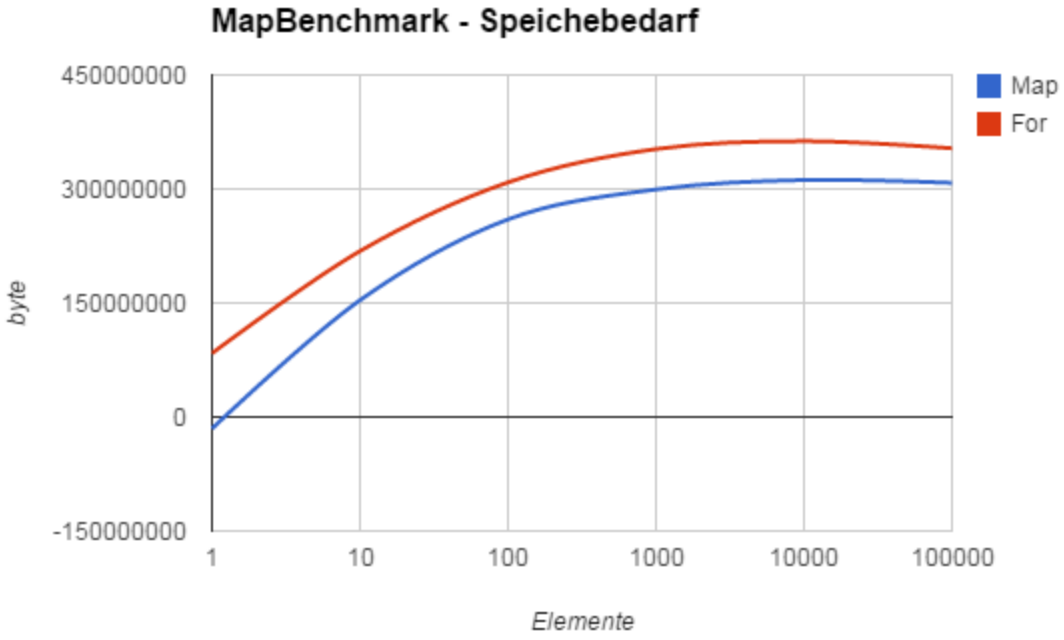

Die Ergebnisse zeigen, dass der Stream, der für `map` erstellt werden muss, beim Erzeugen einen Overhead bei der Laufzeit hat. Diesen Overhead hat die Vorschleife nicht. Allerdings fällt der Overhead bei mehr verarbeiteten Elementen nicht mehr ins Gewicht und `map` und `for` haben in etwa die selbe Laufzeit.
Beim Speicherbedarf hat `for` dagegen einen fixen Speicheroverhead.
Insgesamt schneidet die `map`-Methode besser ab als die `for`-Schleife, da im Test ab 10 Elementen die Laufzeit ausgeglichen, der Speicherbedarf jedoch bei `map` geringer war.

---

filter

Die Methode `filter` gehört zu den grundlegenden Methoden zum Verarbeiten von Datensammlungen. Sie lässt sich zum filtern von Elementen mit bestimmten Eigenschaften nutzen. Der Rückgabewert dieser Methode ist ein Stream aus Elementen, die der Bedingung genügen. Das Prinzip ist beispielsweise aus SQL mit der WHERE Klausel bekannt[23].

Im Stream Interface `Stream<T>` ist die Methode mit folgender Signatur definiert:

```
Stream<T> filter(Predicate<? super T> predicate)
```

Als Argument wird ein Prädikat mit dem Eingabetyp `<? super T>`, bekannt aus `Stream<T>`, gefordert. Die Prädikatsfunktion muss einen `boolean` zurück geben. Die

[23] [SAPI] SQL clauses -> WHERE clause

Methode `filter` produziert wiederum einen `Stream<T>`, also einen Stream vom selben Typ wie der Stream, von dem `filter` aufgerufen wurde.
Die Methode `filter` gehört zu den stateless Methoden.

filter-Benchmark[24]

```
1. list.stream().
2. filter(s -> s.startsWith("a")).
3. forEach(s -> s.length());

4. for(String s : list) {
5.     if(s.startsWith("a")) {
6.         s.length();
7.     }
8. }
```

Zeile 1-3 ist der Aufruf von `filter`, gefolgt von der terminal Methode `forEach` um zu gewährleisten, dass jedes Element aus dem Stream von `filter` bearbeitet wird. In `filter` wird geprüft, ob der erste Buchstabe des Eingabestrings ein ‘a’ ist, in `forEach` wird die Methode `length` auf die übrig gebliebenen Strings aufgerufen. In den Zeilen 4-8 werden die selben Aufrufe mit einer `for`-Schleife mit einer `if`-Abfrage umgesetzt.

[24] [CANH] benchmarks.intermediateMethoden.BenchmarkFilter

Ergebnisse[25]:

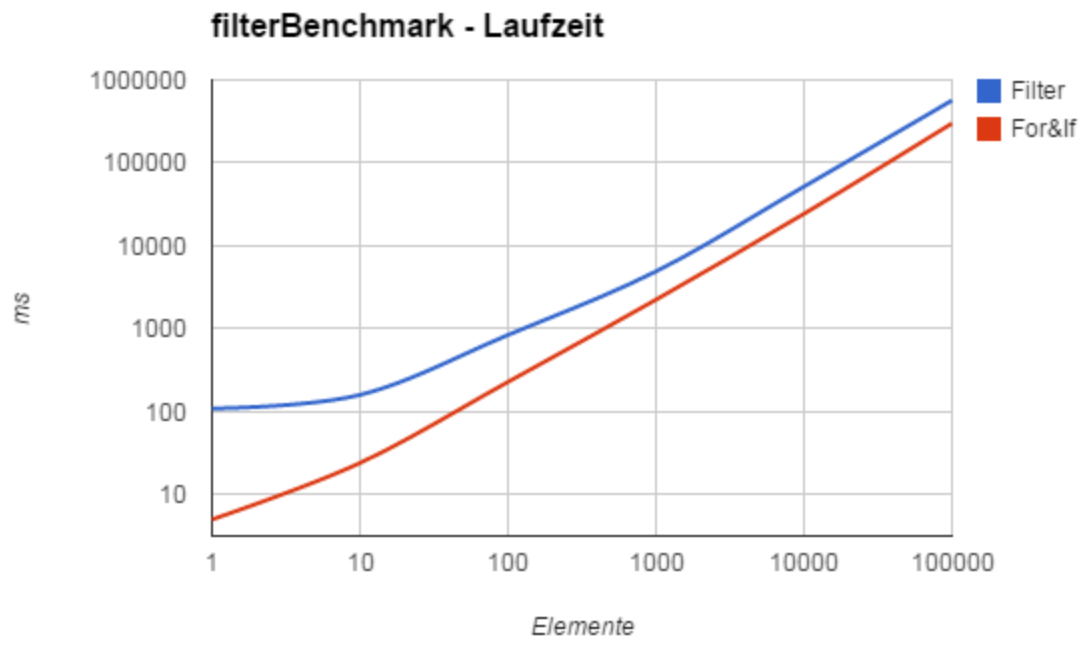

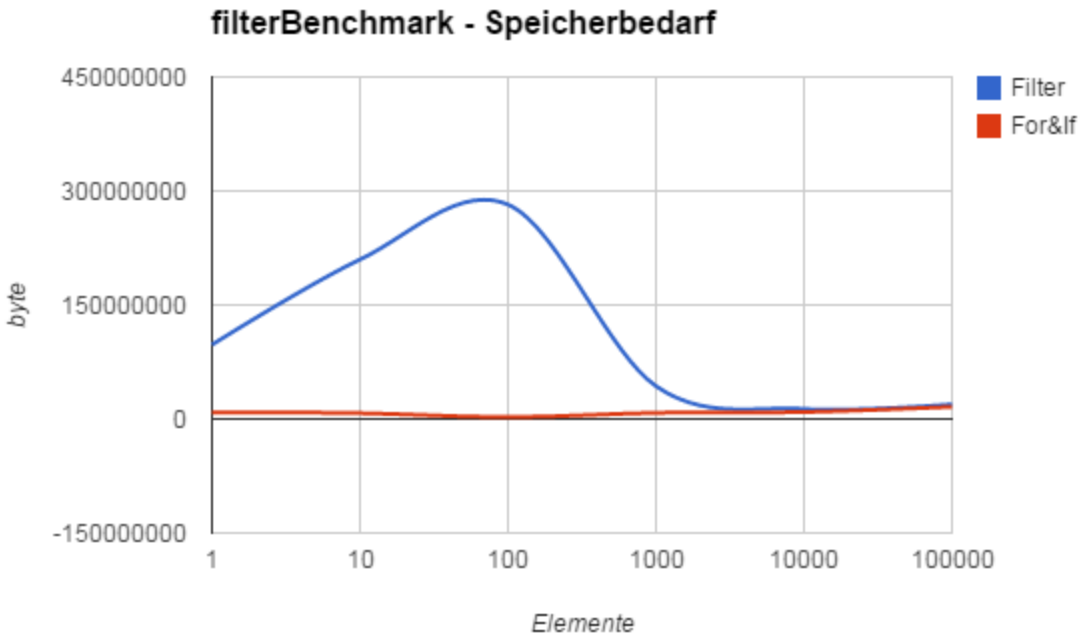

[25] [DANH] Originaloutput als csv-Datei namens “filterBenchmarkOutput.csv”

Die Messergebnisse für Laufzeit zeigen bei wenigen Elementen zunächst wieder den bereits bekannten Laufzeit-Overhead für das Initialisieren des Streams. Mit der steigenden Anzahl verarbeiteter Elemente wird der Laufzeitunterschied zwischen `filter` und `for&if` kleiner, allerdings benötigt der Stream auch bei 100.000 Elementen noch knapp doppelt so viel Laufzeit wie `for&if`. Dieser große Unterschied ist möglicherweise darauf zurückzuführen, dass die `if`-Operation sehr atomar ist und daher vom JIT-Compiler leicht und frühzeitig in nativen Code umgewandelt wird.
Die Messergebnisse für Speicherbedarf zeigen zwischen 1 und 1000 Elementen einen sehr großen Unterschied, bei dem `for&if` wesentlich besser abschneidet als `filter`. Dies ist vermutlich darauf zurückzuführen, dass die Garbage-Collection bei `filter` erst sehr spät angefangen hat zu arbeiten. Zwischen 1.000 und 100.000 Elementen ist der Speicherverbrauch nicht mehr so unterschiedlich, dennoch schneiden `for&if` auch hier noch um ungefähr ein Drittel besser ab als `filter`.
Insgesamt schneiden `for&if` bedeutend besser ab als `filter`.

---

sorted

Mit der Methode `sorted` lässt sich eine Datenquelle sortieren. Dies kann mit der unverarbeiteten Datenquelle, zwischen zwei Bearbeitungsschritten oder zuletzt vor der Ausgabe der verarbeiteten Datenquelle passieren. In der Regel kann eine Vergleichsfunktion angegeben werden, mit der die einzelnen Elemente untereinander verglichen werden. Generell ist es empfehlenswert, dass die Laufzeit der Vergleichsfunktion in O(1) liegt, da das Sortieren ansonsten sehr viel Laufzeit in Anspruch nehmen kann. Bekannt ist diese Funktion unter Anderem aus SQL mit der Klausel ORDER BY[26].

Im Stream Interface `Stream<T>` ist die Methode mit den folgenden Signaturen definiert:

```
Stream<T> sorted()
Stream<T> sorted(Comparator<? super T> comparator)
```

`sorted` ohne Argumente verlangt, dass T das Interface `Comparable` implementiert, ansonsten wird bei Aufruf der terminal Methode am Ende des Streams eine `ClassCastException` geworfen[27]. `sorted` mit einem `Comparator`, also einer Vergleichsfunktion als Argument fordert dies nicht, dafür muss die Vergleichsfunktion selber definiert oder zumindest übergeben werden. Die Vergleichsfunktion muss Elemente vom Typ `<? super T>` verarbeiten und einen Rückgabewert vom Typ `int` haben.

[26] [SAPI] vgl. SQL clauses -> ORDER BY clause
[27] [J8API] vgl. java.util.stream.Stream<T>

sorted-Benchmark[28]

```
1. list.stream().
2.     sorted(String::compareTo).
3.     forEach(s -> s.length());

4. Collections.sort(list, String::compareTo);
5. for(String s : list) {
6.     s.toUpperCase().length();
7. }
```

Zeile 1-3 ist der Aufruf von `sorted` gefolgt von der terminal Methode `forEach` um zu gewährleisten, dass jedes Element aus dem Stream von `sorted` bearbeitet wird. Obwohl `sorted` stateful ist und schon beim Abruf von einem Element alle Elemente des vorhergehenden Streams bearbeitet, wurde hier `forEach` mit `length` als Operation als terminal Methode gewählt um eine bessere Vergleichbarkeit zwischen den anderen verschiedenen Benchmarks herzustellen. Die Zeilen 4-7 sind eine zu `sorted` möglichst ähnliche Abfolge von Operationen die unter Java 7 verfügbar waren. In Zeile 2 wird die Datenquelle mit `Collections.sort` komplett sortiert. In den Zeilen 3 und 4 wird mit einer `for`-Schleife über die sortierte Liste iteriert und die `length` Methode für jedes Element aufgerufen. Die Ergebnisse der beiden Benchmarks unterscheiden sich darin, dass `Collection.sort` ein Mutator ist, `Stream.sorted` dagegen nicht.

Ergebnisse[29]:

[28] [CANH] benchmarks.intermediateMethoden.BenchmarkSorted
[29] [DANH] Originaloutput als csv-Datei namens “sortedBenchmarkOutput.csv”

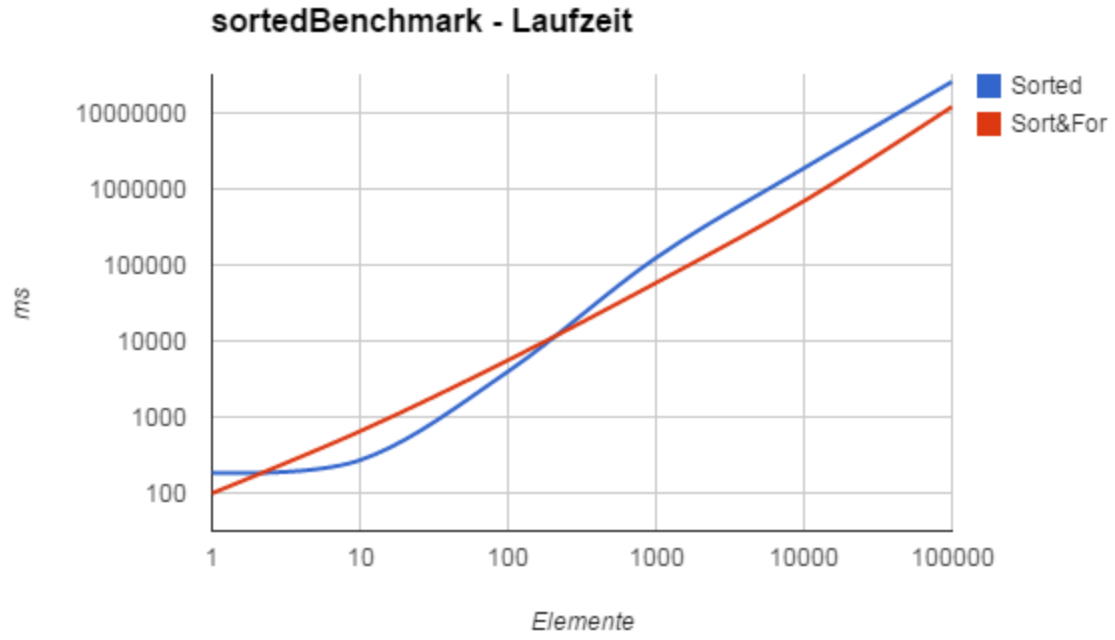

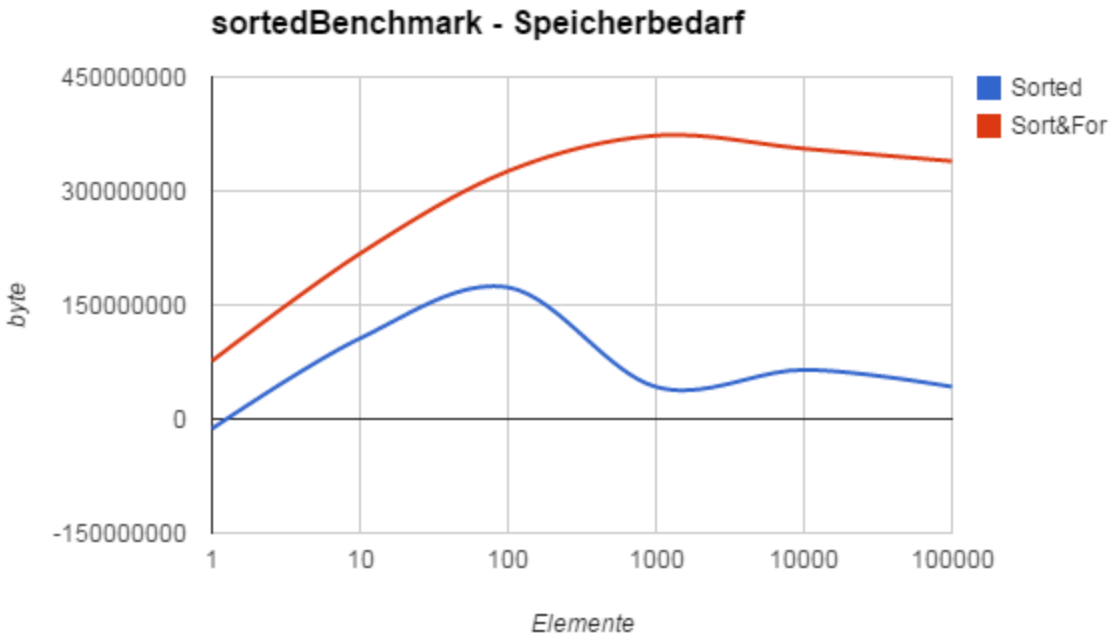

Die Messergebnisse für Laufzeit zeigen bei wenigen Elementen zunächst wieder den bereits bekannten Laufzeit-Overhead für das Initialisieren des Streams. Bei ca 100 und weniger Elementen hat `sorted` eine geringere Laufzeit als `Sort&For`. Allerdings ist der Laufzeitanstieg von `Sort&For` durchgängig linear, wogegen der von `sorted` nach gut 100 Elementen stark ansteigt und erst dann linear weiter steigt. Für sehr viele Elemente ist

`Sort&For` besser als `sorted`, für wenige 100 Elemente ist hingegen `sorted` effizienter oder gleichwertig effizient.
Die Messergebnisse für Speicherbedarf zeigen, dass `sorted` mit Abstand weniger Speicher benötigt als `Sort&For`. Wenn zwischen 100 und 1000 verarbeiteten Elementen die Garbage-Collection angesprungen ist, wird sogar noch weniger Speicher benötigt. Der höhere und anfangs relativ lineare Anstieg des Speicherbedarfs von `Sort&For` ist vermutlich darauf zurück zu führen, dass eine vollständige sortierte Kopie der Liste erstellt wird, was `sorted` nicht in dem Umfang tun muss. Zudem sind in der Kopie der Liste sämtliche Meta-Informationen, die diese mit sich bringt, enthalten. Bei vielen Elementen springt allerdings auch hier die Garbage-Collection an und löscht die nicht mehr benötigte Ursprungsliste aus dem Arbeitsspeicher.
Zusammenfassend ist zwar der Speicherbedarf von `sorted` wesentlich geringer als der von `Sort&For`, dafür ist bei vielen Elementen die Laufzeit von `Sort&For` um ungefähr 40% kürzer als die von `sorted`. Da beim Sortieren aber die Laufzeit oftmals der entscheidene Faktor ist muss hier je nach Situation entschieden werden was die bessere Methode ist.

Terminal Methoden

Eine terminal Methode ist das Endstück in der Stream-Pipeline. Wenn eine terminal Methode aufgerufen wurde und terminiert ist gilt der Stream als verbraucht und kann nicht mehr benutzt werden. Wie auch intermediate Methoden unterstützen einige terminal Methoden lazy evaluation, wodurch unendliche Streams in vielen Fällen terminieren können. Terminal Methoden konsumieren in der Regel die Elemente des aufrufenden Streams. Nur die Ausnahmen `iterator` und `spliterator` tun dies nicht, sondern erlauben dem Nutzer das eigenständige Traversieren über die Elemente aus dem aufrufenden Stream. Terminal Methoden sind verantwortlich dafür, Anfragen an die Stream-Pipeline zu stellen, sodass von der Quelle aus Elemente bis zur terminal Methode durchgereicht werden.
Im Gegensatz zu intermediate Methoden können einige terminal Methoden wie `forEach` und `peek` Seiteneffekte haben. Diese sind allerdings wie alle Seiteneffekte mit Vorsicht zu benutzen und können besonders bei parallelen Streams ungewünschte Effekte haben, wenn die aufgerufenen Methoden oder Variablen der Elemente nicht threadsave sind.
Terminal Methoden haben keinen weiteren zu verarbeitenden Stream, sondern können einzelne Elemente oder Informationen über den Stream als Rückgabewert haben. Beispiele hierfür sind `anyMatch`, `findFirst` oder `match`[30].

Im Folgenden werden einige wichtige terminal Methoden vorgestellt und Benchmarks[31] für diese gezeigt. Anschließend werden sie mit Java7-Alternativen verglichen.

[30] vgl. [J8API] java.util.stream
[31] Alle Benchmarks wurden mit dem Programm Benchmark Tool durchgeführt. (s. Anhang)

forEach

Das Traversieren über alle Elemente einer Datenquelle um diese Elemente zu manipulieren gehört zu den grundlegenden Methoden der imperativen Programmierung. Dies wird mit der Methode `forEach`, oder auch nur `for` genannt, in den meisten imperativen und Objekt orientierten Sprachen umgesetzt. Auf diese Weise können Aktionen, die für jedes Element einer Datenquelle ausgeführt werden sollen, in wenigen Zeilen und unabhängig von der Menge der Elemente durchgeführt werden. Des Weiteren lassen sich mit dieser Hilfe beliebige Suchen leicht umsetzen. Bekannt ist das Prinzip beispielsweise aus C[32] mit dem `for`-Statement oder früheren Java-Versionen.

Im Stream Interface `Stream<T>` ist die Methode mit der folgenden Signatur definiert:

```
void forEach(Consumer<? super T> action)
```

`forEach` hat als Argument eine Consumer-Funktion, welche Elemente vom Typ `<? super T>` verarbeitet. Als Rückgabewert hat `forEach` `void`, also nichts. Dafür kann die Consumer-Funktion, die als Argument an `forEach` übergeben wurde, Seiteneffekte haben.
Bei der Verarbeitung von parallelen Streams ist `forEach` explizit nicht deterministisch. Dies würde eine Einhaltung der Reihenfolge der Elemente fordern, was den Vorteil der Parallelisierung zunichte machen würde. Das heißt, dass für jedes Element die Consumer-Funktion zu jedem möglichen Augenblick und in jedem möglichen Thread ausgeführt werden kann. Falls die Reihenfolge der Elemente entscheidend ist, kann auf die Funktion `forEachOrdered` zugegriffen werden, welche diese beibehält[33].

forEach-Benchmark[34]

```
1. list.stream().
2.     forEach(s -> s.toUpperCase());

3. for(String s : list) {
4.     s.toUpperCase();
5. }
```

Die Zeilen 1 und 2 sind der `forEach`-Benchmark. Dabei wird aus einer Liste fünfstelliger Strings ein Stream erzeugt, welcher mit der terminal Methode `forEach` verarbeitet wird. In `forEach` werden die Elemente mit `toUpperCase` bearbeitet. Die Zeilen 3-5 sind der Vergleichstest mit einer `for`-Schleife. Die Strings werden wie in `forEach` mit `toUpperCase` bearbeitet.

[32] vgl. [ISO9899] 6.8.5.3 “The for statement”
[33] vgl. [JAPI] java.util.stream.Stream<T>
[34] vgl. [CANH] benchmarks.terminalMethoden.BenchmarkForEach

Ergebnisse[35]:

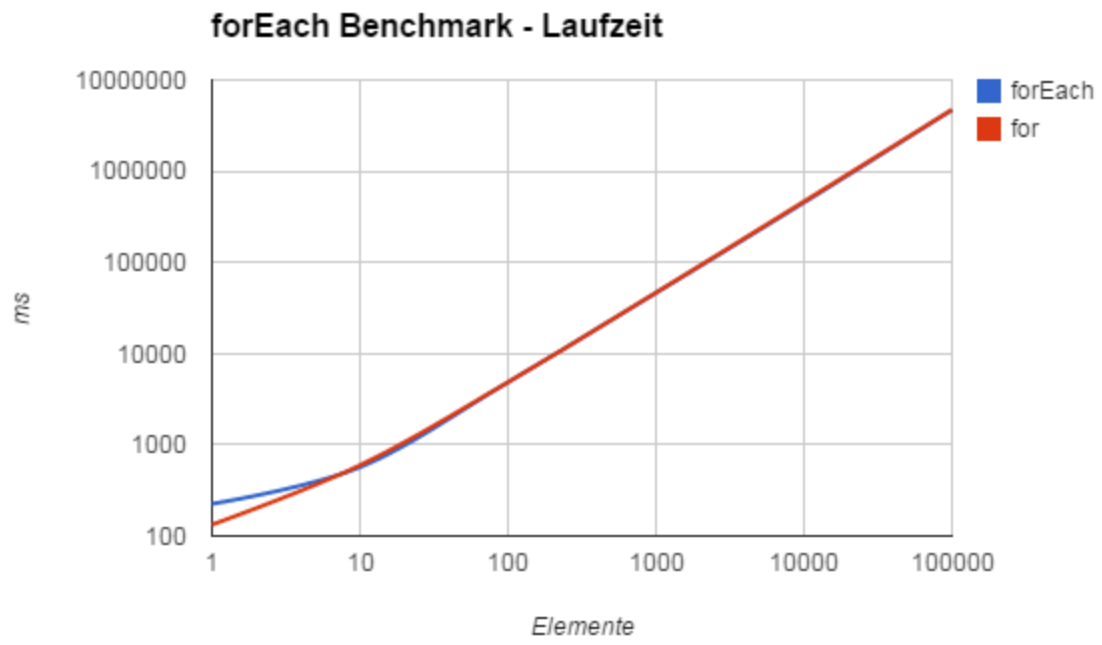

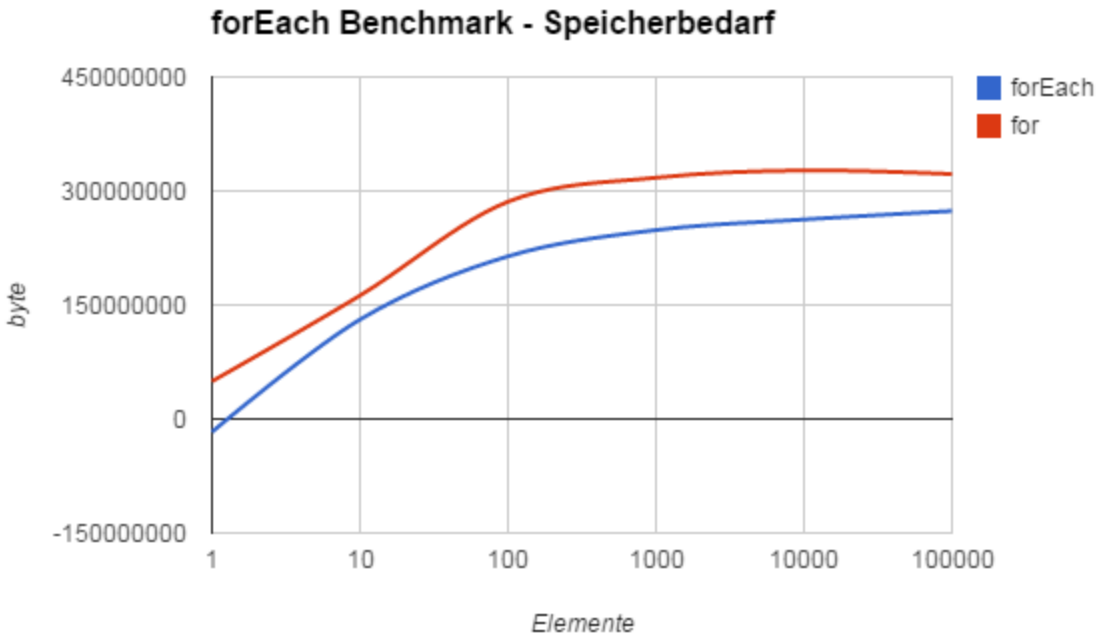

Die Messergebnisse für Laufzeit zeigen bei wenigen Elementen für `forEach` zunächst den bereits bekannten Laufzeit-Overhead für das Initialisieren des Streams. Bei einer Menge von

[35] [DANH] Originaloutput als csv-Datei namens “forEachBenchmarkOutput.csv”

ca 10 Elementen fällt dieser aber nicht mehr ins Gewicht und die Laufzeit steigt für beide Methoden linear an.
Beim Speicherbedarf hat `for` einen fixe Menge bytes mehr belegt als `forEach`. Da aber beide Methoden im Bereich zwischen 1.000 und 10.000 Elementen konstant werden, fällt dieser zusätzliche Speicherbedarf bei einer großen Menge Elemente nicht mehr ins Gewicht.
Insgesamt schneidet `forEach` aufgrund des geringeren Speicherbedarfs leicht besser ab als `for`. Allerdings sind die Ergebnisse nicht so verschieden, dass diese ein ausschlaggebendes Argument für eine der beiden Methoden darstellt.

---

reduce

`reduce` wird dafür verwendet alle Elemente in einer Datenquelle zu einem einzelnen Element zu reduzieren. Dafür benötigt `reduce` eine Datenquelle und eine Akkumulationsfunktion, um die Elemente der Datenquelle miteinander zu akkumulieren. So können zum Beispiel viele verschiedene Zählungen zu einer Zählung reduziert werden.
Bekannt ist diese Methode beispielsweise aus funktionalen Programmiersprachen wie Haskell [36] unter dem Namen `fold` oder aus dem map-reduce-Prinzip[37].

Im Stream Interface `Stream<T>` ist die Methode mit den folgenden Signaturen definiert:

```
T reduce(T identity, BinaryOperator<T> accumulator)
Optional<T> reduce(BinaryOperator<T> accumulator)
```

Die erste Signatur erwartet ein Identitätselement vom Typ `T`, welches als Basiselement für die Akkumulationsfunktion genutzt wird. Die Akkumulationsfunktion erwartet zwei Elemente vom Typ `T`. Als Rückgabewert hat diese Signatur ein Element vom Typ `T`.
Die zweite Signatur erwartet kein Identitätselement und hat ansonsten, wie auch die erste Signatur, eine Akkumulationsfunktion für Elemente vom Typ T als Argument. Als Rückgabewert hat die zweite Signatur im Gegensatz zur ersten ein `Optional<T>`. Dies ist darauf zurück zu führen, dass die erste Signatur durch ihr Identitätselement immer einen Rückgabewert hat, dies aber bei der zweiten Signatur nicht garantiert ist, weil der Stream auch leer sein kann.
Keine der Versionen von `reduce` garantiert eine Abarbeitungsreihenfolge, sodass die Akkumulationsfunktion das Assoziativgesetz einhalten muss[38].
Im `Stream<T>`-Interface existiert eine speziellere Version von `reduce` namens `collect`. Diese ist dafür gedacht, mit Methoden aus dem `Collectors`-Interface aus Stream-Elementen neue Datenstrukturen wie Collections zu generieren.
Des Weiteren existiert die folgende Signatur, die ich hier nicht weiter betrachten werde:

[36] [HAPI] fold
[37] [DGMR]
[38] [J8API] vgl. java.util.stream.Stream<T>

```
<U> U reduce(U identity, BiFunction<U,? super T,U> accumulator,
BinaryOperator<U> combiner)
```

reduce-Benchmark[39]

```
1. list.stream().
2.     reduce("", (s1, s2) -> String.join(" ", s1, s2));

3. String akku = "";
4. for(String s : list) {
5.     akku = String.join(" ", akku, s);
6. }
```

In den Zeilen 1 und 2 ist der `reduce` Benchmark. In Zeile 1 wird ein Stream aus einer Liste fünfstelliger Strings erzeugt. In der zweiten Zeile wird `reduce` mit einem leeren String als neutralem Element und `String.join` als Akkumulationsmethode aufgerufen.
In den Zeilen 3 bis 6 steht der Vergleichsbenchmark mit einem Akkumulator in Zeile 3 und einer `for`-Schleife in den Zeilen 4-6. Der Akkumulator wird mit dem neutralen Element initialisiert und dann in Zeile 5 mit `String.join` in jedem Schleifendurchlauf mit jedem neuen String-Element konkateniert.

Ergebnisse[40]:

[39] vgl. [CANH] benchmarks.terminalMethoden.BenchmarkReduce
[40] [DANH] Originaloutput als csv-Datei namens “reduceBenchmarkOutput.csv”

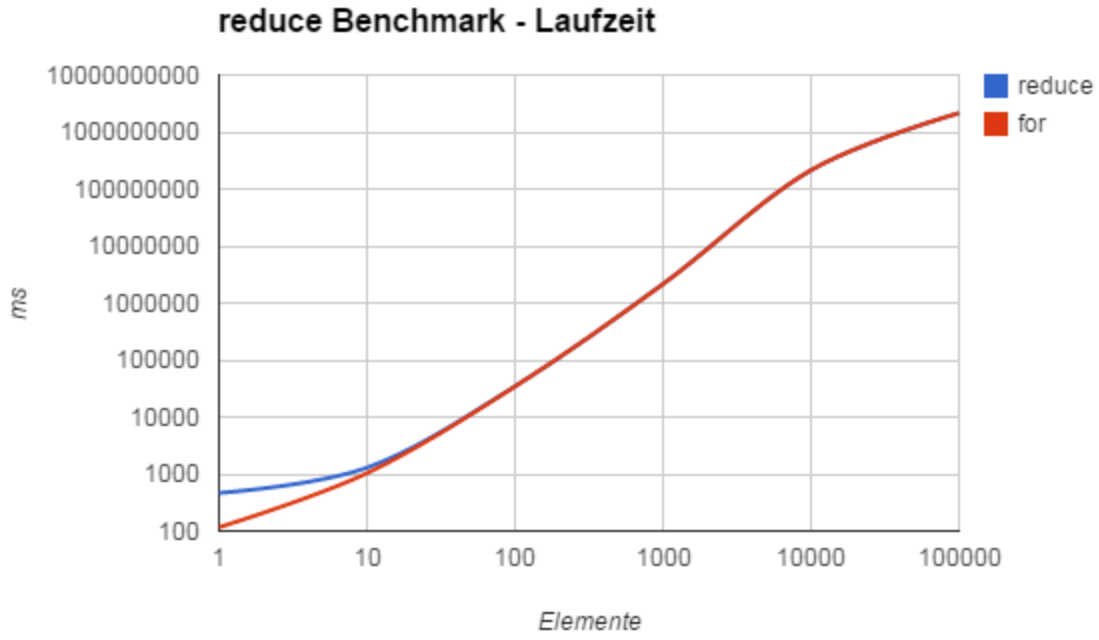

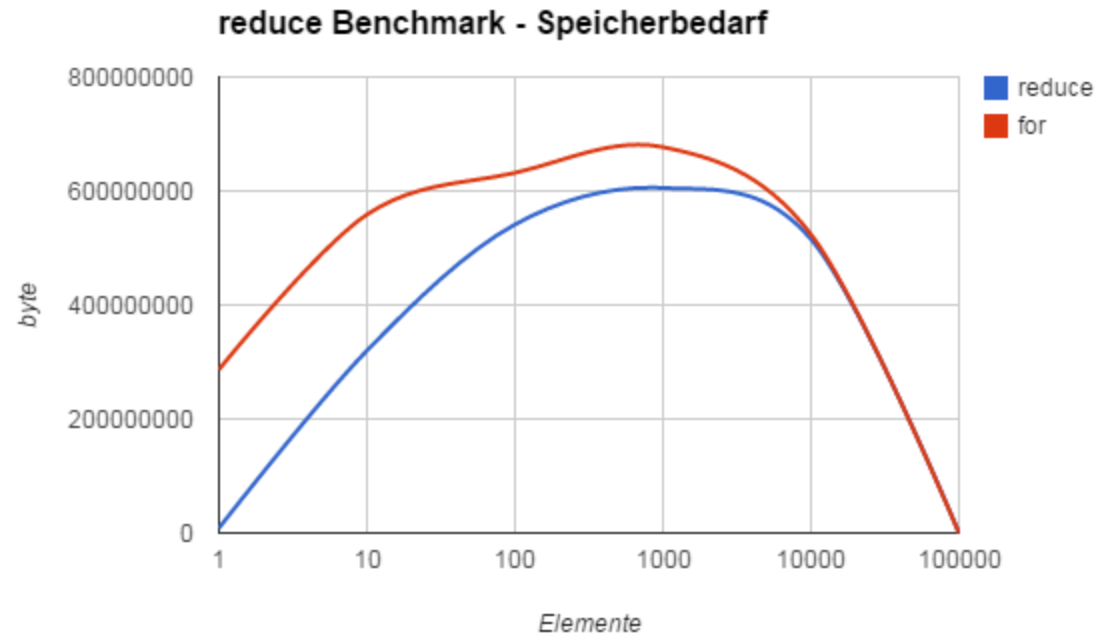

Die Messergebnisse für Laufzeit zeigen bei wenigen Elementen für `reduce` zunächst den bereits bekannten Laufzeit-Overhead für das Initialisieren des Streams. Bei mehr als ca. 10 Elementen fällt dieser Overhead nicht mehr ins Gewicht und beide Methoden nehmen den selben Verlauf. Dabei ist zu beobachten, dass von 10.000 zu 100.000 Elementen die Laufzeit weniger stark ansteigt als bei weniger Elementen.

Bei der Speicherbedarfsmessung zeigt sich, dass die `for`-Schleife besonders bei wenigen verarbeiteten Elementen sehr viel mehr Speicher verbraucht als `reduce`. Bei steigender Elementzahl nähern sich die Messungen allerdings aneinander an.
Auffallend ist die Messungen für 100.000 Elemente bei beiden Methoden. In mehrfachen Durchläufen war das Ergebnis für den Speicherverbrauch jedes Mal, bei beiden Methoden, genau 2024. Dieses Ergebnis ist mit aller Wahrscheinlichkeit ein Messfehler und wird daher nicht weiter berücksichtigt.
Insgesamt hat `reduce` aufgrund der zwar selben Laufzeit wie `for`, aber des zum Teil wesentlich niedrigeren Speicherbedarfs, besser abgeschnitten als `for`. Eine Empfehlung kann hier nicht ausgesprochen werden, da die Messergebnisse möglicherweise nicht zuverlässig sind. Dies liegt vermutlich daran, dass der Speicherbedarf aufgrund der, bei vielen Elementen langen zu verarbeitenden Strings, zu groß für eine Messung wird.

Short-Circuit Methoden

Short-circuit Methoden sorgen dafür, dass vorhergegangene intermediate Methoden mit lazy evaluation nur so viele Elemente verarbeiten, bis die short-circuit Methode terminieren kann[41].
Short-circuit Methoden zeichnen sich dadurch aus, dass sie oftmals nicht alle oder nur ein einzelnes Element aus der vorhergegangenen intermediate Methode benötigen.
Eine short-circuit Methode kann sowohl zu den terminal, als auch zu den intermediate Methoden gehören. Beispiele hierfür sind `limit` und `skip` aus den intermediate Methoden und `findFirst` und `allMatch` aus den terminal Methoden[42].

Im Folgenden werden einige wichtige terminal Methoden vorgestellt und Benchmarks[43] für diese gezeigt. Anschließend werden diese mit Java7-Alternativen verglichen.

findFirst

`findFirst` ist dazu gedacht, das erste aufgefundene Element aus einer Datenquelle zurückzugeben. Vor eine solche Methode wird in der Regel eine Methode zum aussortieren, wie im Kapitel `filter` beschrieben, geschaltet. Wenn nur wenige Elemente aus der Datenquelle der Bedingung von `filter` entsprechen und dementsprechend möglicherweise viele Elemente verarbeitet werden, bis eines zu `findFirst` durchgereicht wird. Hier kann es sinnvoll sein, das vorgeschaltete `filter` zu parallelisieren.
Bekannt ist findFirst zum Beispiel aus SQL mit dem `FIRST` Statement[44] oder Haskell mit der Funktion `find`[45].

---

[41] vgl. [MHS1] Folie 44
[42] vgl. [MHS1] Folie 44
[43] Alle Benchmarks wurden mit dem Programm Benchmark Tool durchgeführt. (s. Anhang)
[44] vgl. [SAPI] SQL clauses -> The result offset and fetch first clauses
[45] vgl. [HAPI] find

Im Stream Interface `Stream<T>` ist die Methode mit der folgenden Signatur definiert:

```
Optional<T> findFirst()
```

Die Methode erwartet kein Argument und hat als Rückgabewert einen `Optional<T>` für den Fall, dass die vorhergegangene intermediate Methode kein Element liefern kann. Wenn der Stream auf dem `findFirst` aufgerufen wurde keine Ordnung hat, kann ein beliebiges Element aus diesem Stream im zurückgegebenen `Optional<T>` enthalten sein[46]. Da `findFirst`, wie der Name sagt, nur ein Element benötigt um zu terminieren, werden hierdurch in vielen Fällen viele unnötige Rechenoperationen übersprungen.

findFirst-Benchmark[47]

```
1. Optional<String> o = list.stream().
2.     filter(s -> s.startsWith("sound")).
3.     findFirst();

4. if(o.isPresent()) {
5.     o.get().toUpperCase();
6. }

7. for(String s : list) {
8.     if(s.startsWith("sound")) {
9.          s.toUpperCase();
10.         return;
11.     }
12.   }
```

In den Zeilen 1-6 ist der Benchmark für `findFirst`. Dabei wird in den Zeilen 1-3 ein Optional `o` mittels `filter` und `findFirst` aus einer Liste mit einem Stream geholt. Das gesuchte Element befindet sich an Stelle 20 der Liste. In Zeile 4 wird geprüft, ob `o` ein Element enthält, also ob das betreffende Wort gefunden wurde. Wenn ja wird `toUpperCase` darauf angewandt.
In den Zeilen 7-12 ist der Vergleichsbenchmark mit einer `for`-Schleife und einem `if` zum filtern. Wenn ein Element gefunden wurde was dem `if` genügt dann wird, wie beim `findFirst`, `toUpperCase` darauf angewandt.
Obwohl `toUpperCase` nicht direkt mit dem Auffinden eines Elements in einem Stream oder einer Liste zu tun hat, ist es diese Methode hier im Benchmark zu verwenden. Wenn Anlass besteht ein Element aus einer Datenquelle zu suchen, dann wird dieses auch benutzt werden. Da dies im Fall des `for&if` einfacher geht als bei `findFirst`, weil kein Optional mehr

[46] vgl. [J8API] java.util.stream.Stream<T>
[47] vgl. [CANH] benchmarks.shortCircuitMethoden.BenchmarkFindFirst

geprüft werden muss, sollte die Benutzung des gefundenen Elementes Teil eines praxisrelevanten Tests sein.

Ergebnisse[48]:

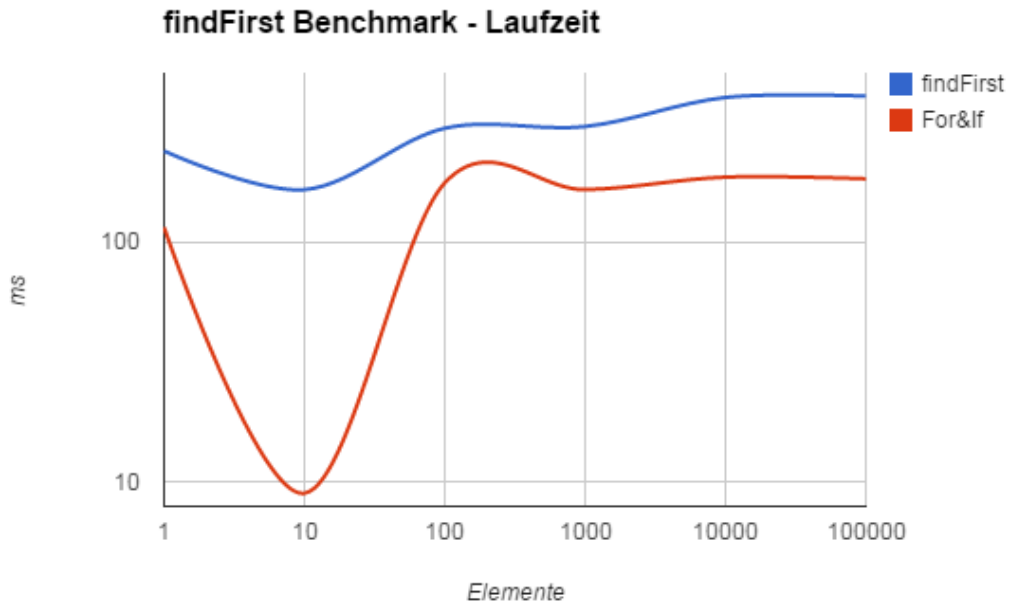

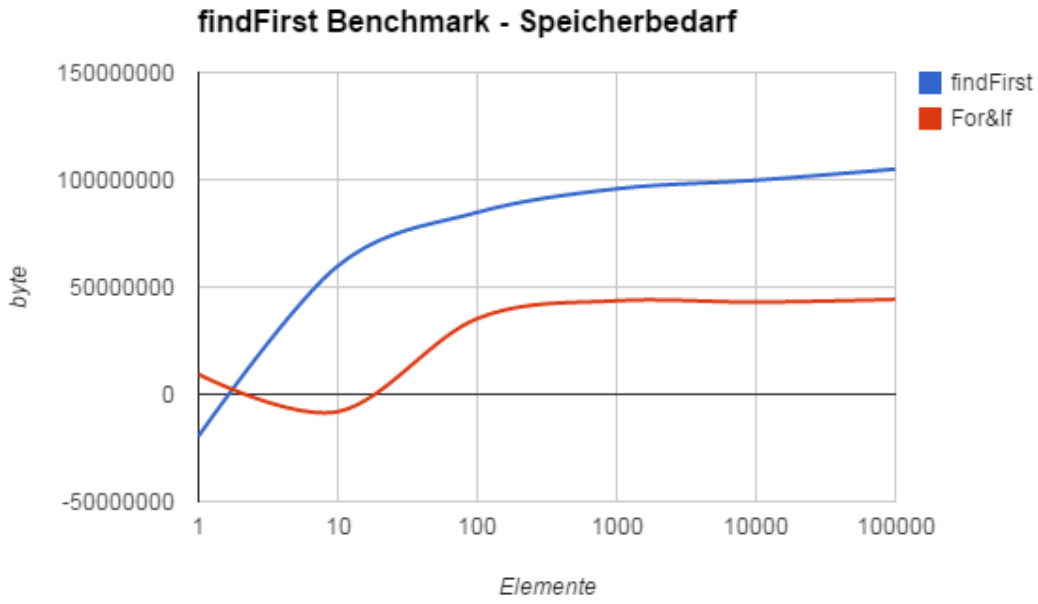

[48] [DANH] Originaloutput als csv-Datei namens “findFirstBenchmarkOutput.csv”

Die Laufzeitergebnisse zeigen, dass `for&if` um eine zumeist fixe Zeit schneller laufen als `findFirst`. Diese fixe Zeit ist vermutlich dem geschuldet, dass für `findFirst` zunächst ein Stream initialisiert werden und nach dem Finden des Elements noch ein `Optional` bearbeitet werden muss. Nach 100 Elementen bleibt die Laufzeit bei beiden Methoden relativ konstant. Dies liegt daran, dass das zu findende Element an Stelle 20 der Datenquelle zu finden ist. Bei einer Liste von 10 Elementen zeigen beide Methoden eine sehr kurze Laufzeit, wobei die von `for&if` kürzer ausfällt. Dass diese bei `for&if` extrem gering ist ist vermutlich einem Messfehler zuzuschreiben.
Die Speicherbedarfsmessung zeigt, dass `findFirst` eine fixe Menge mehr Speicher benötigt als `for&if`. Diese ist vermutlich dem zu speichernden `Optional` zuzuschreiben. Ansonsten fällt auf, dass der Speicherbedarf für `findFirst` mit einer steigenden Anzahl Elemente weiter ansteigt, obwohl nur 20 Elemente der Datenquelle verarbeitet werden müssen. Dies ist bei `for&if` nicht der Fall.
Insgesamt schneiden `for&if` sowohl bei Speicherbedarf als auch Laufzeitmessung besser ab als `findFirst`. Dies liegt allerdings daran, dass nur ein Bruchteil der Elemente verarbeitet werden muss und so ein Großteil der Laufzeit und des Speicherbedarfs durch den Overhead von Streams oder Optionals belegt wird.

---

limit

Diese Methode limitiert die Anzahl der weitergegebenen Elemente auf einen fixen Wert. Dies findet dann Einsatz, wenn zum Beispiel nur wenige Elemente für eine Berechnung gebraucht werden oder die benutzte Datenquelle zu groß ist um alle Elemente aus ihr zu verarbeiten.
Bekannt ist diese Methode besonders aus Datenbanken wie MongoDB mit der Aggregation `limit`[49].

Im Stream Interface `Stream<T>` ist die Methode mit der folgenden Signatur definiert:

```
Stream<T> limit(long maxSize)
```

`limit` erwartet als Argument einen `long maxSize`, der die maximale Anzahl der weiter zu gebenden Elemente bestimmt. Da `limit` eine intermediate Methode ist gibt sie einen `Stream<T>` für das nächste Glied in der Stream-Pipeline zurück. In einem sequentiellen Stream garantiert `limit`, dass nicht nur irgendwelche Elemente weiter geben werden, sondern die ersten `maxSize` Elemente aus dem vorherigen Stream. Dies kann bei einem parallelen geordneten Stream zu großen Performanceeinbußen führen. Wenn die Ordnung der Elemente hier nicht mehr notwendig ist empfiehlt es sich, mit der Methode `unordered` aus BaseStream den Stream ungeordnet zu verwenden[50].

[49] vgl. [MAPI] operator -> aggregation -> limit
[50] vgl. [J8API] java.util.stream.Stream<T>

limit-Benchmark[51]

```
1. list.stream().
2.     limit(20).
3.     forEach(s -> s.toUpperCase());

4. long counter = 0;
5. for(String s : list) {
6.     if(counter >= 20) {
7.         return;
8.     }
9.     s.toUpperCase();
10.    counter++;
11.   }
```

In den Zeilen 1-3 befindet sich der Benchmark für `limit`. In der ersten Zeile wird ein Stream aus einer Liste fünfstelliger Strings erzeugt. In Zeile 2 wird die Anzahl der Elemente auf 20 beschränkt und in Zeile 3 werden diese Elemente mit `toUpperCase` verarbeitet.
In den Zeilen 4-11 ist der Benchmark für die Vergleichsmethode mit `for&if`. In Zeile 4 wird ein Zähler initialisiert und in Zeile 10 in jedem Durchlauf der Schleife in den Zeilen 5-11 inkrementiert. In Zeile 6 wird geprüft, ob schon 20 Elemente verarbeitet wurden, und im Fall von 20 abgeschlossenen Inkrementationen mit `return` terminiert.

[51] vgl. [CANH] benchmarks.shortCircuitMethoden.BenchmarkLimit

Ergebnisse[52]:

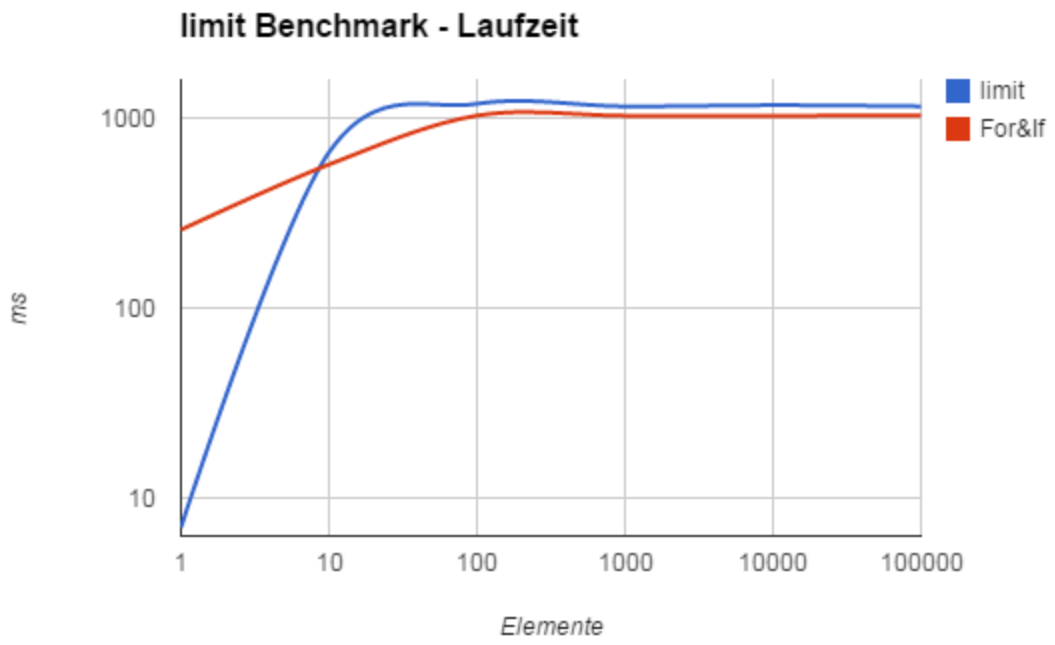

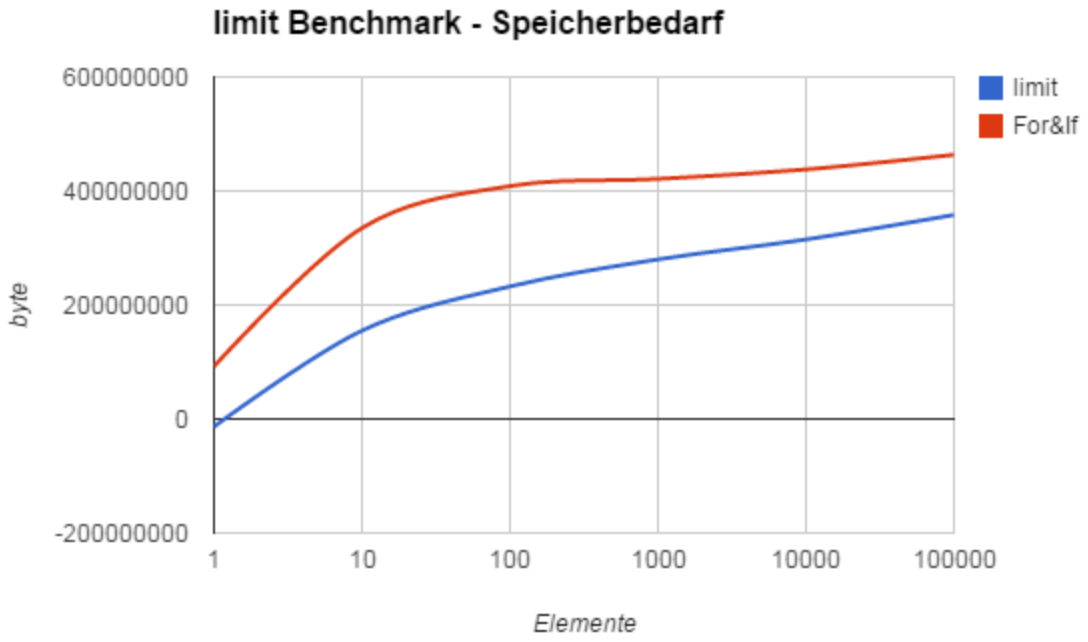

Die Ergebnisse für Laufzeit zeigen, dass beide Methoden eine ähnliche Laufzeit haben. Aus dem Muster fällt das Messergebnis für 1 Element bei `for&if`, welches sehr hoch ausfällt.

[52] [DANH] Originaloutput als csv-Datei namens “limitBenchmarkOutput.csv”

Dies ist vermutlich eine Messungenauigkeit. Ansonsten läuft `for&if` nur unwesentlich schneller als `limit`. Bei 100 Elementen steigt die Laufzeit nicht mehr weiter an. Dies ist auf die Begrenzung von maximal 20 verarbeiteten Elementen zurückzuführen.
Die Ergebnisse für den Speicherbedarf zeigen, dass `for&if` eine, in etwa konstante Menge mehr Speicherbedarf als `limit`, hat. Auffällig ist, dass der Speicherbedarf bei beiden Methoden auch nach 100 Elementen noch weiter ansteigt, obwohl die Begrenzung bei 20 Elementen liegt.
Insgesamt schneidet `limit` leicht besser ab als `for&if`. Dies liegt daran, dass der Speicherbedarf von `limit` niedriger ist als der von `for&if`, welcher sich aber bei einer größeren Anzahl von `limit` und `for&if` zugelassener Elemente relativieren sollte. In der Laufzeit unterscheiden sich `limit` und `for&if` nur bei sehr wenigen Elementen.

Fazit

Mit Streams scheint versucht worden zu sein, positive Eigenschaften aus vielen verschiedenen Sprachen in Java zu vereinen. Zum einen wird die Syntax durch Lambda-Methoden und vielen vorgegebenen, oft benötigten, Methoden wie `limit` oder `map` übersichtlicher. Zum anderen werden Seiteneffekte bei intermediate Methoden komplett verboten, sodass eine Parallelisierung, ähnlich wie in funktionalen Sprachen, relativ einfach durchzuführen ist.
Lazy evaluation scheint eine sehr gute Methode zu sein, um Performanceeinbußen durch Programmierfehler zu vermeiden. Beispielsweise ist es mit `limit` nicht mehr möglich, innerhalb einer Stream-Pipeline unnötigerweise eine Datenquelle erst komplett zu verarbeiten und dann nur die ersten 20 Elemente daraus zu benutzen. Wenn allerdings mit Funktionen, die vor Java 8 verfügbar waren, sauber gearbeitet und keine Rechenzeit verschwendet wird, bringt dies keinen Vorteil. Im Gegenteil kostet es Laufzeit durch das Initialisieren des Streams.
Insgesamt wird empfohlen Streams zu benutzen, denn Streams werden vermutlich in den nächsten Java-Versionen weiter verbessert. Des Weiteren kann die Möglichkeit der automatischen Parallelisierung, die hier nicht genauer betrachtet wurde, die Laufzeit fast linear mit steigender Prozessorzahl verringern. Dies wäre Inhalt einer weiteren wissenschaftlichen Arbeit.

Quellen

[MHS1] Hall, Marty: “Streams in Java8: Part1”. http://www.java-programming.info/tutorial/pdf/java/java-8/Java-8-Streams-Part-1.pdf (27.12.2014).

[MHS2] Hall, Marty: “Streams in Java8: Part2”. http://www.java-programming.info/tutorial/pdf/java/java-8/Java-8-Streams-Part-2.pdf (27.12.2014).

[CANH] Giersch, Steffen: Codeanhang an diese Hausarbeit. Am besten zu Öffnen als Eclipse-Projekt. Referenzen werden aus dem Ordner /src angegeben.

[DANH] Giersch, Steffen: Ordner in dem sich dieses Dokument befindet.

[DGMR] Dean, Jeffrey & Ghemawat, Sanjay: “MapReduce: Simplified Data Processing on Large Clusters”. OSDI, 2004.

[J8API] Oracle: “Java 8 API”. http://docs.oracle.com/javase/8/docs/api/ (27.12.2014).

[HAPI] Mitchell, Neil: “Hoogle” https://www.haskell.org/hoogle/ (02.01.2015).

[SAPI] Oracle & Apache Software Foundation “Apache Derby”, Kapitel “SQL language reference”. http://docs.oracle.com/javadb/10.8.3.0/ref/ (08.01.2015).

[MAPI] MongoDB. Inc: “The MongoDB 2.6 Manual”, Kapitel “Reference”. http://docs.mongodb.org/manual/reference/ (17.01.2015).

[ISO9899] ISO/IEC 9899: “Programming Languages - C” http://www.open-std.org/jtc1/sc22/wg14/www/docs/n1124.pdf (14.01.2015)

[SGBW] Knuth, Donald E.: “SGB-Words”. http://www-cs-faculty.stanford.edu/~uno/sgb.html (02.01.2015).

Anhang

Benchmark Tool

Für das Benchmarking wurde das für die zweite Praktikumsaufgabe erweiterte Benchmarktool auf Basis von Kent Becks Micro-Framework verwendet. Zu finden ist dieses Tool in [CANH] im Package benchmarkTool.

Das generelle Vorgehen dieses Benchmark-Tools ist zunächst die Laufzeit und den Speicherbedarf für das Aufrufen einer leeren Methode zu messen. Auf diese Weise soll der Overhead der zu benchmarkenden Methode bestimmt werden. Daraufhin wird die zu benchmarkende Methode aufgerufen und auch hier Laufzeit und Speicherbedarf gemessen. Zwischen je zwei Methodenaufrufen wird die Java Garbage-Collection aufgerufen und eine Sekunde gewartet um für jede Messung einen möglichst gleichmäßigen Startzustand in der JVM zu schaffen. Um auf dem PC der den Benchmark durchführt bei jedem Benchmark

möglichst vergleichbare Startbedingungen zu haben wurde dieser vor jedem Durchlauf neu gestartet.

Die Elemente der zu bearbeitenden Datenquellen sind Strings aus Donald E. Knuths SGB-Words[53] (5757 verschiedene 5-Stellige Wörter) um gleichlange und gleichzeitig praxisrelevante Eingabelemente zu verarbeiten.

Das Ergebnis des Benchmarkings sind die vom Overhead bereinigte Laufzeit und der vom Overhead bereinigte Speicherbedarf für verschieden große bearbeitete Datenquellen.

[53] [SGBW]